Documentación Final del Proyecto:

Análisis de Mercado Airbnb Buenos Aires

- Autor: Augusto Bossi
- Rol: Data Analyst
- Institución: Digital House

- Fecha: 03/2026

Índice

Documentación Final del Proyecto: 1

Análisis de Mercado Airbnb Buenos Aires 1

1. Introducción y Objetivo del Proyecto 1
2. Exploración y Tratamiento de Datos (Proceso ETL) 1
3. Modelado y Creación del Dashboard en Power BI 3
4. Desafíos del Proyecto y Cambio de Perspectiva 4
5. Aprendizajes y Conclusiones del Proceso 4

1. Introducción y Objetivo del Proyecto

El presente proyecto tiene como finalidad actuar como una herramienta de consultoría basada en datos para potenciales inversores inmobiliarios en la Ciudad Autónoma de Buenos Aires. El objetivo principal es responder a preguntas de negocio críticas: en qué zonas invertir, qué tipo de propiedad maximiza el retorno de inversión (ROI) y cómo es el panorama competitivo actual.

2. Exploración y Tratamiento de Datos (Proceso ETL)

La limpieza y transformación de datos es una de las tareas más críticas para garantizar la calidad en cualquier proyecto de análisis. A continuación, se detalla el proceso completo de Extracción, Transformación y Carga (ETL) aplicado al dataset, justificando cada decisión técnica tomada.

1. Extract (Extracción)

En esta fase, se procedió a la lectura de las fuentes originales de datos utilizando la librería Pandas en Python.

- Se cargó el archivo principal de propiedades (listings.csv), el cual contenía inicialmente 23.729 filas y 106 columnas.
- Se cargó el archivo de disponibilidad temporal (calendar.csv) con 8.661.286 registros.
- **Justificación:** Se aislaron los datos crudos en variables independientes (df_listings, df_calendar) para mantener la integridad de los datos originales antes de aplicar cualquier mutación.

2. Transform (Transformación)

Esta fue la etapa más exhaustiva, enfocada en resolver inconsistencias, manejar valores faltantes y preparar las variables para el análisis exploratorio. Se documenta cada paso a continuación:

- **Paso T1 - Poda Inicial de Nulos:** Se utilizó df.isnull().sum() para auditar el dataset. Se detectaron y eliminaron 12 columnas que poseían más del 50% de valores nulos (ej. notes, square_feet, license).
    - Justificación: Mantener variables con un nivel tan alto de ausencia introduce ruido y no aporta valor estadístico significativo al modelo.
- **Paso T2 - Casteo de Tipos de Datos:** * Se transformaron las variables monetarias (price, security_deposit, cleaning_fee, extra_people) eliminando el símbolo $ y convirtiéndolas a formato numérico (float).

    - Se utilizó pd.to_datetime() para convertir correctamente las columnas de fechas (host_since, first_review, last_review).
    - Justificación: Es un paso obligatorio para permitir cálculos estadísticos y análisis de series temporales.
- **Paso T3 - Imputación Financiera y Tratamiento de Outliers:** * Se rellenaron los nulos de security_deposit y cleaning_fee con $0.
    - Se identificaron y eliminaron 2.083 propiedades con precios atípicos (outliers) utilizando límites estadísticos.
    - Justificación: Asumimos que la ausencia de un depósito de seguridad o tarifa de limpieza implica que no se cobra. Eliminar los outliers en el precio previene que la media se sesgue, distorsionando el análisis de mercado.
- **Paso T4 - Normalización de Datos:** Se aplicó la técnica de Min-Max Scaler a la variable number_of_reviews.
    - Justificación: Ajustar esta variable a una escala de 0 a 1 permite compararla equitativamente con otras métricas, preparándola para posibles modelos de machine learning o índices ponderados en etapas posteriores.
- **Paso T5 - Integración y Creación de Variables Derivadas:** Se agruparon los datos de df_calendar utilizando groupby() para calcular el promedio de días disponibles por propiedad. Luego, se unió (merge) esta nueva variable (porcentaje_disponibilidad) al dataset principal df_listings.
    - Justificación: En lugar de cruzar las tablas directamente (lo que hubiera multiplicado las filas exponencialmente), se creó una variable derivada agregada, enriqueciendo el dataset principal sin romper su granularidad.
- **Paso T6 & T7 - Feature Selection e Imputación Estratégica:** * Se eliminaron 14 columnas de texto libre (ej. description, interaction) que no se utilizarán.
    - Se imputaron los valores faltantes en las métricas del anfitrión y de las reseñas (review_scores_..., host_response_rate) utilizando la **mediana**.
    - Justificación: Se descartaron los textos largos para optimizar el peso del archivo. Se utilizó la mediana (y no el promedio o cero) para rellenar las calificaciones faltantes, evitando penalizar a las propiedades nuevas sin historial y manteniendo la distribución original de los datos.

- **Paso T8 - Cierre de Nulos Temporales:** Se rellenaron los nulos en reviews_per_month con 0. Las fechas de first_review y last_review vacías se mantuvieron como nulas.
    - Justificación: Los nulos en estas columnas no son "errores", sino que representan propiedades que nunca fueron alquiladas o reseñadas. Colocar un "0" en la tasa mensual es lógicamente correcto, pero inventar una fecha arruinaría la integridad referencial.

3. Load (Carga)

Finalmente, el dataset procesado fue exportado.

- **Acción:** Se guardó el DataFrame limpio como airbnb_limpio_final.csv eliminando el índice del DataFrame original (index=False).
- **Resultado:** Se obtuvo un dataset consolidado con dimensiones de (21.448 filas, 79 columnas), 100% libre de nulos críticos y con formatos consistentes.
- **Justificación:** El almacenamiento en un archivo plano unificado y limpio asegura que los datos estén listos para ser ingeridos por herramientas de visualización o para análisis exploratorio profundo en la siguiente fase del proyecto.

Conclusión

El proceso de ETL aplicado logró reducir la dimensionalidad innecesaria, corregir formatos erróneos y estandarizar las métricas clave sin comprometer la veracidad de la información original. Con este dataset transformado y estructurado, garantizamos un punto de partida robusto y de alta calidad para extraer insights precisos y generar visualizaciones avanzadas en la Etapa III.

3. Modelado y Creación del Dashboard en Power BI

Una vez obtenido el dataset limpio (airbnb_limpio_final.csv), se procedió al desarrollo del tablero interactivo:

- **Justificación de Diseño:** Se adoptó un enfoque minimalista y de "tipo aplicación", utilizando contenedores con bordes redondeados y fondos claros para reducir la carga cognitiva. Se utilizó la paleta de colores corporativa de Airbnb (Rojo Coral) para resaltar los *insights* principales frente a una paleta secundaria de grises y verdes.
- **Estructuración:** El tablero se dividió en tres páginas secuenciales (Panorama General, Precios/Rentabilidad y Competencia) para guiar al usuario desde una vista macro hasta las recomendaciones operativas.

4. Desafíos del Proyecto y Cambio de Perspectiva

Durante el desarrollo del análisis, los mayores obstáculos no fueron únicamente de índole técnica, sino estratégicos y de enfoque analítico. Enfrentarse a este volumen de información requirió un cambio de mirada:

- **De la saturación de datos a la claridad del negocio:** El primer gran desafío al explorar más de 21.000 propiedades fue la tentación de graficar todas las variables disponibles. El proceso me obligó a cambiar la perspectiva: comprendí que el valor de un analista no reside en mostrar la mayor cantidad de información posible, sino en tener el criterio para filtrar el ruido y destacar únicamente los datos que responden a las preguntas del inversor. "Menos es más" se convirtió en la regla fundamental.
- **Romper sesgos cognitivos con evidencia empírica:** Al iniciar el proyecto, existía la preconcepción natural de que subdividir una propiedad para alquilarla por habitaciones o tener una calificación perfecta de 100/100 garantizarían el mejor retorno. El desafío fue dejar de lado la intuición y permitir que los datos contaran la historia real. Descubrir el "techo de precio" de las habitaciones privadas o el verdadero peso de la insignia *Superhost* fue un aprendizaje clave sobre cómo los datos a menudo desafían el sentido común.
- **Diseño centrado en el usuario final:** Otro reto importante fue la traducción del trabajo técnico al lenguaje de negocios. Inicialmente, el enfoque estaba puesto en la complejidad de los cruces de datos, pero rápidamente se hizo evidente que un dashboard complejo no es un dashboard útil. El verdadero desafío fue simplificar la interfaz, limpiar el lenguaje técnico y diseñar una experiencia visual que permitiera a un cliente tomar una decisión de inversión en cuestión de minutos y sin requerir asistencia técnica.

5. Aprendizajes y Conclusiones del Proceso

- **El rol del Storytelling en los datos:** El mayor aprendizaje del proyecto fue interiorizar que una base de datos limpia y un modelo estadístico robusto carecen de impacto si no están acompañados de una narrativa clara. Los números no hablan por sí solos; necesitan contexto, jerarquía visual y un hilo conductor que guíe al tomador de decisiones.
- **La importancia del entendimiento del negocio:** Dominar herramientas como Python o Power BI es solo el requisito básico. El verdadero diferencial adquirido en este proyecto fue la capacidad de ponerse en los zapatos del cliente, entendiendo que variables como la

"disponibilidad" o el "tipo de propiedad" no son solo columnas en un archivo CSV, sino factores de riesgo y rentabilidad en la vida real.

- **Toma de decisiones fundamentada:** El proyecto culmina demostrando el poder del análisis de datos para mitigar la incertidumbre. El resultado final no es solo un tablero interactivo, sino una recomendación estratégica sólida y accionable para ingresar al mercado inmobiliario turístico de Buenos Aires con las mayores probabilidades de éxito.